

썸네일, 영상 제목을 이용한 유튜브 카테고리 분류

염예진 이유경 이영송 서지완 김민석

# INDEX



- 01** 프로젝트 개요
- 02** 데이터 수집 및 전처리
- 03** 1차 모델 생성/예측/평가
- 04** 특성 추출
- 05** 전체 모델 비교
- 06** 결과 해석



## 01 프로젝트 개요

- 주제 선정 이유
- 프로젝트 진행 순서



## 주제 선정 이유



꽃보다 달리

조회수 14,780회 • 2020. 4. 21.

1.5천 7 공유 7 저장 ...



달려라 달리  
구독자 17.6만명

꽃향기 맡는 것을 참 좋아하는 달리  
예쁜 꽃과 함께 한 귀여운 달리의 모습을 모아봤어요  
모두 힐링하세요~

Bgm  
Patrick Ussher - Song of the Butterflies Strings version  
카테고리 인물/블로그

#로또908회자동 #907회자동 #로또자동  
로또 908회 수요일자동 30장(150게임)

조회수 1,820회 • 2020. 4. 22.



만수르형  
구독자 3.68만명

#로또908회자동 #907회자동 #로또자동  
만수르형밴드 - <https://band.us/n/ada212FeleY3A>  
로또 908회 수요일자동 30장(150게임)

카테고리 인물/블로그

간략히

#해외주식 #디즈니 #애플

폭발하는 해외 투자와 우리가 사랑하는 글로벌 주식들

조회수 235,856회 • 2020. 4. 20.




슈카월드  
구독자 65.6만명

어렵고 딱딱한 경제, 시사, 금융 이야기를  
쉽고 유쾌하게 풀어내는  
경제/시사/이슈/잡설 토크방송입니다.

#해외주식 #디즈니 #애플

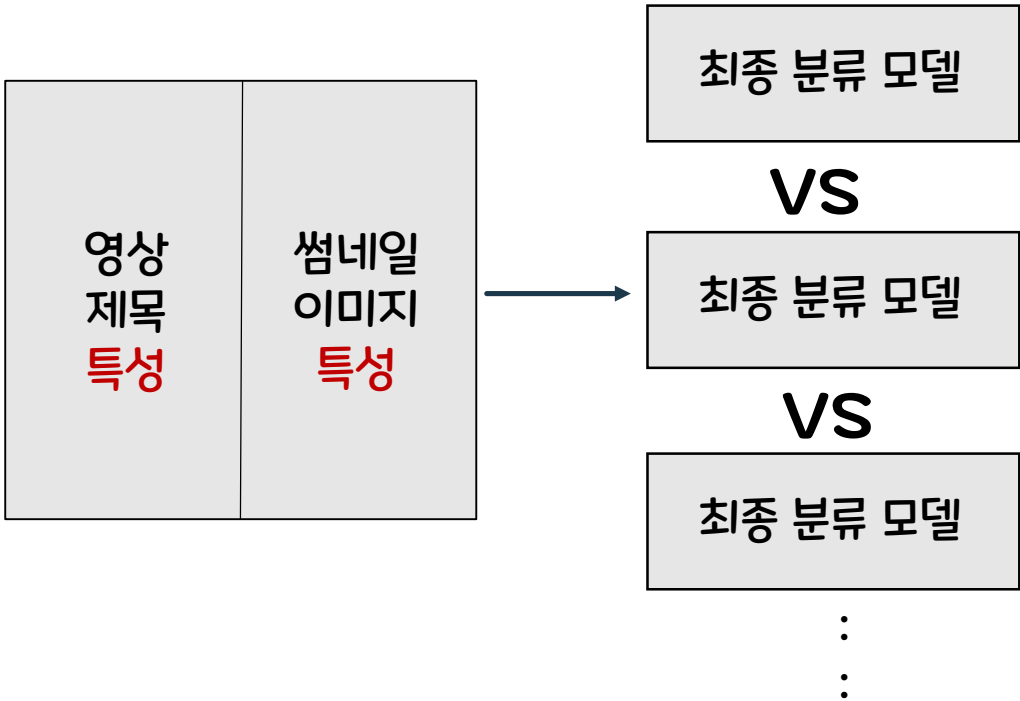
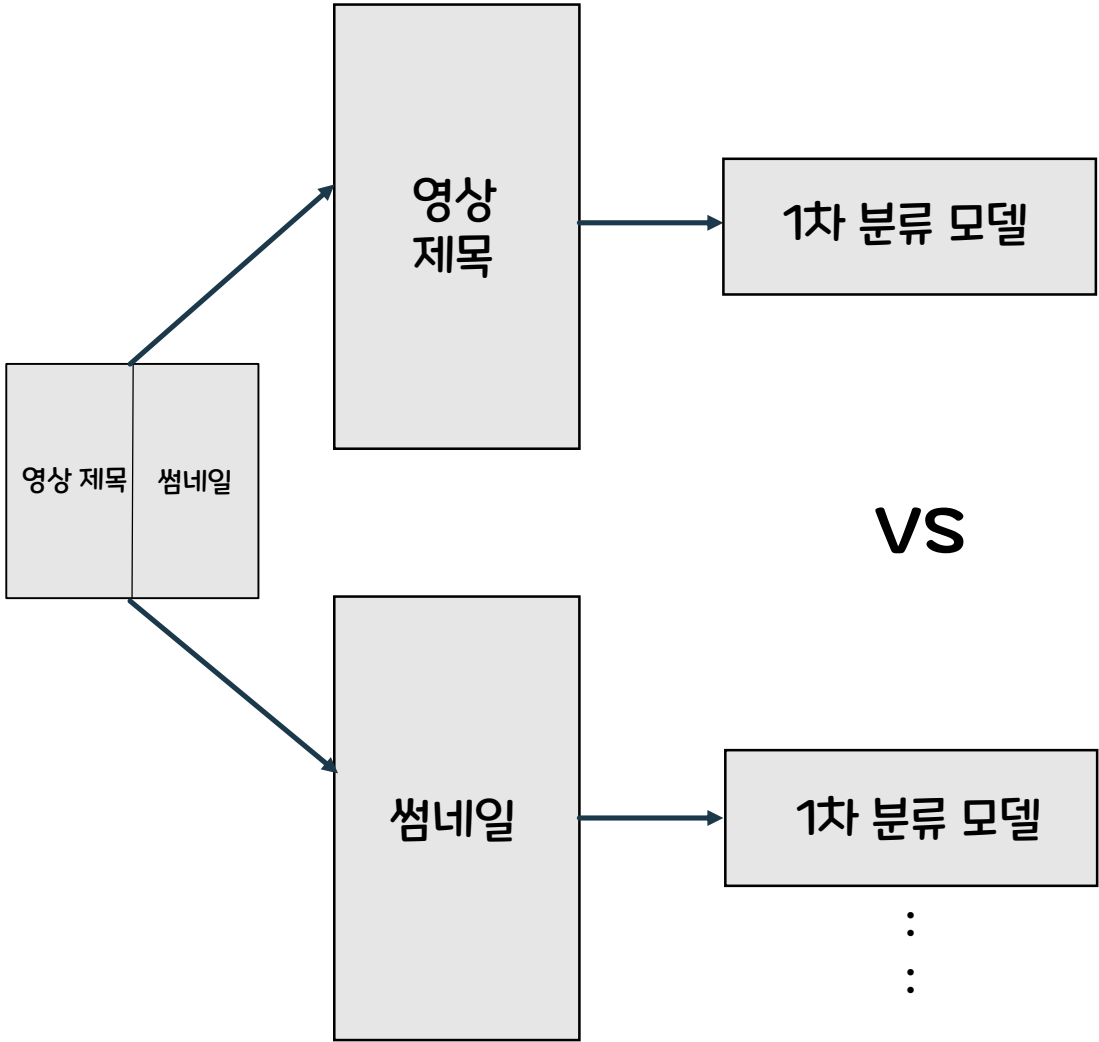
카테고리 코미디

카테고리 분류가  
잘못된 것들이 있네.  
어떻게 하면  
분류 정확도를  
높일 수 있을까?





# 프로젝트 진행 순서





## 02 데이터 수집 및 전처리

- YouTube 데이터 크롤링
- EDA
- 영상 제목 전처리
- 썸네일 이미지 전처리

# Youtube 데이터 크롤링

7개의 카테고리 직접 설정


0 : cooking



1 : economy




2 : game



3 : movie



4 : pets



5 : politics




6 : sports







# Youtube 데이터 크롤링




**MochaMilk**  
구독자 101만명

구독중


🔔

홈 동영상 재생목록 커뮤니티 채널 정보 🔍


업로드한 동영상 ▾ 모두 재생 정렬 기준




고양이 장애물 피하기를 강아지가 해보았더니?ㅋㅋㅋㅋ  
조회수 51만회 · 1일 전




강아지는 왜 아기를 지극정성으로 보살폈던걸까? 1 뒤바뀐...  
조회수 117만회 · 5일 전




다시 반년만에 라이브로 인사드려요 😊  
조회수 20만회 · 1주 전




아빠 혼자 놀러갔다고 빠진 강아지  
조회수 93만회 · 1주 전




스테이크 처음 먹어본 강아지! 강아지 스테이크 먹방  
조회수 90만회 · 2주 전  
자막




강제 격리되어 슬픈 강아지의 하루  
조회수 55만회 · 3주 전  
자막




강아지 앞에서 우는척 했다 진짜 울면 했어요..  
조회수 53만회 · 4주 전




사모에드의 유일한 단점, 털! 3일동안 사모에드 털을 모아...  
조회수 324만회 · 1개월 전  
자막



길에서 마주친 엄마가 모른척 지나가자 슬픈 눈빛 보내는 ...  
조회수 68만회 · 1개월 전




강아지에게 갑자기 들이대 불편함을 주어 보았다! 불편한...  
조회수 46만회 · 1개월 전  
자막



막상 해보니 맘에 들었나봐요 :)  
I think Wooyoo likes it :)

▶ ⏮ ⏭ 🔊 2:08 / 10:11

#사모에드 #강아지스파 #나도하고싶다베스랑  
묵묵하는데 이렇게 귀엽기 있기 없기?  
조회수 2,129,142회 · 2019. 1. 20.  
👍 4.9만 💬 603 ➦ 공유 📌 저장 ⋮



MochaMilk  
구독자 101만명

구독중

🔔

1) 유튜버의 모든 동영상의 썸네일 이미지 크롤링

2) 동영상의 제목, 채널이름 데이터 크롤링





# Youtube 데이터 크롤링

7개의 카테고리, 전체 13685개의 데이터 수집

	channel_name	video_name	category_id	thumbnail
0	복덩이	너무나맛있는 '알타리묵은지찜과' "앞치마에그림" Altari old paper st...	0	<a href="https://i.ytimg.com/vi/al52wJgMGyl/hqdefault.j...">https://i.ytimg.com/vi/al52wJgMGyl/hqdefault.j...</a>
1	복덩이	현웃으로만든 [앞치마]와 '민들레' 겹절이 'Apron' made with old ...	0	<a href="https://i.ytimg.com/vi/-xx7shznKec/hqdefault.j...">https://i.ytimg.com/vi/-xx7shznKec/hqdefault.j...</a>
2	복덩이	탈모와다이어트에 탁월하고급진 '느타리버섯볶음' 과 프로방스 창문그리기 Stir-fr...	0	<a href="https://i.ytimg.com/vi/m7KC7oEKKuo/hqdefault.j...">https://i.ytimg.com/vi/m7KC7oEKKuo/hqdefault.j...</a>
3	복덩이	감기 면역력 간기능보호에 탁월한 '도라지튀김' '민들레튀김' '라벤다그리기' Fri...	0	<a href="https://i.ytimg.com/vi/FYeuMGEgNWA/hqdefault.j...">https://i.ytimg.com/vi/FYeuMGEgNWA/hqdefault.j...</a>
4	복덩이	진달래화전 부침 복덩이표 바삭바삭한 쫄쫄독비법공개	0	<a href="https://i.ytimg.com/vi/UjLKW2fjkyA/hqdefault.j...">https://i.ytimg.com/vi/UjLKW2fjkyA/hqdefault.j...</a>
...	...	...	...	...
13680	키다리형	[VLOG] 체지방 한자릿수 유지식단::뭐든지 과하면 독이다 :: 추억의 VLOG	6	<a href="https://i.ytimg.com/vi/gPEWgwBoT6l/hqdefault.j...">https://i.ytimg.com/vi/gPEWgwBoT6l/hqdefault.j...</a>
13681	키다리형	[키용소 2화] 그들의 입맛을 사로잡은 식단 대공개 (맛있게 다이어트하자)	6	<a href="https://i.ytimg.com/vi/p7Ssy5gB_5A/hqdefault.j...">https://i.ytimg.com/vi/p7Ssy5gB_5A/hqdefault.j...</a>
13682	키다리형	[실속2분팁] 덤벨로우 tip (넓고 두꺼운 등을 위하여)	6	<a href="https://i.ytimg.com/vi/PI7UN15-5K0/hqdefault.j...">https://i.ytimg.com/vi/PI7UN15-5K0/hqdefault.j...</a>
13683	키다리형	[키용소 1화] 살빼는방법을 모르겠어요 :: 위험한 계약	6	<a href="https://i.ytimg.com/vi/il4-fi64bss/hqdefault.j...">https://i.ytimg.com/vi/il4-fi64bss/hqdefault.j...</a>
13684	키다리형	[VLOG] 다이어트를 위한 식단과 운동 :: 키용소1기 친구들과 함께한 하루	6	<a href="https://i.ytimg.com/vi/cgp-OT0CEKc/hqdefault.j...">https://i.ytimg.com/vi/cgp-OT0CEKc/hqdefault.j...</a>

13685 rows × 4 columns



## 영상 제목 전처리

\* 총 4가지의 형태소 분석기 사용

- (1) Okt의 nouns
- (2) Kkma의 nouns
- (3) Soynlp의 word
- (4) Soynlp의 noun

	형태소 분석 방법	단점
Okt	<ul style="list-style-type: none"> <li>- 오픈소스 한국어 텍스트 분석기</li> <li>- 로딩시간이 상당히 빠름</li> </ul>	완전한 수준의 형태소 단위의 분석을 하기 힘들다
Kkma	<ul style="list-style-type: none"> <li>- 세종 말뭉치를 구조화하고, 이로부터 통계적으로 생성된 말뭉치를 조회</li> <li>- 형태소 단위의 분석을 지향</li> </ul>	로딩 시간이 길다
Soynlp	말뭉치를 cp*에서 학습하고 이를 기반으로 주어진 문장을 토큰화	늘 새로운 단어가 만들어지기 때문에 학습하지 못한 단어를 제대로 인식하지 못하는 oov 발생

\* Cohesion Probability

연속된 글자의 연관성이 높을수록 단어일 가능성이 높다는 가정 하에 구축된 모델

$$\begin{aligned}
 cohesion(c_1, c_2, \dots, c_n) &= \sqrt[n]{\prod_{i=1}^{n-1} P(c_1, \dots, c_{i+1} | c_1, \dots, c_i)} \\
 &= \sqrt[n]{\frac{Freq(c_1, c_2, \dots, c_n)}{Freq(c_1)}}
 \end{aligned}$$



## 1. 토큰화 전, 노이즈 제거

{ } [ ] < > 《 》 「 」 『 』 【 】 ‘ ’ “ ” 、 。 …… § ※ ☆ ★ ○  
● ◎ ◇ ◆ □ ■ △ ▲ ▽ ▼ ◁ ▷ ▶ ♠ ♥ ♣  
♣ ⊙ ◆ ▣ ● ☾ ☼ ▨ ▩ ▭ ▮ ▯ ± × ÷ ≠ ≤ ≥ ∞ ∴ ∫ ∏ ∈ ∃ ⊆ ⊇ ⊂  
⊃ ∪ ∩ ∧ ∨ ¬ ⇒ ⇔ ∀ ∃ ′ ~ ¨ ° ° ‚ ; : ™ Σ Π  
b j k l ® → ← ↑ ↓ ↔ ↕ ↗ ↘ \ (주) No. Co. ™ am. pm. Tel  
☎ ☑ ☒ ☓ ☔ ☕ ☖ ☗ ☘ ☙ ☚ ☛ ☜ ☝ ☞ ☟ ☠ ☡ ☢ ☣ ☤ ☥ ☦ ☧ ☨ ☩ ☪ ☫ ☬ ☭ ☮ ☯ ☰ ☱ ☲ ☳ ☴ ☵ ☶ ☷ ☸ ☹ ☺ ☻ ☼ ☽ ☿ ☽ ☿

### (1) 특수문자



## (2) 이모지

A B C D E F G  
H I J K L M N  
O P Q R S T U  
V W X Y Z

### (3) 영어

0 1 2 3 4  
5 6 7 8 9

#### (4) 숫자

## 2. 불용어 사전 정의

이, 있, 하, 것, 들, 그 ...

## (1) 코퍼스 빈도어 상위 100개

최주부  
별인러브  
냥이아빠  
정치합시다  
백수골방  
김재원의 즐거운게임 세상  
등등

## (2) 채널명

알못도, 원하, 하세요,  
준, 브리, 줄, 탄  
...

(3) 눈으로 확인할 수 있는 몇몇 단어



# 영상 제목 전처리

## 3. 명사 단위로 토큰화 (okt, kkma, soynlp)

영상 제목	Okt 형태소 분석기의 명사 단위로 토큰화된 영상 제목
나이키 축구화 때문에 벌금 1,000만원 낸 김병지 축구화 썰	[나이키, 축구화, 만원, 김병지, 축구화]
매콤곱창볶음   술안주로 제격인 곱창볶음으로 월요일 마무리하기 [만개의레시피]	[매콤, 곱창, 볶음, 술안주, 곱창, 볶음, 월요일, 마무리, 레시피]
청와대 앞 조국 땀에 난리났다. 조국특검 문정권탄핵 기자회견.(190910)	[청와대, 조국, 난리, 조국, 특검, 정권, 탄핵, 기자회견]
총선 D-7, 트로트요정이 투표송을..?😳상큼미 폭발하는 이채윤의 투표송 도전기💪 ...	[총선, 트로트, 정이, 투표, 폭발, 투표, 도전, 정치]
SUB) 귀찮은 그라탕은 이젠 빠엎~!😍😍😍 치즈베이컨그라탕 ★ [만개의레시피]	[그라탕, 치즈, 베이컨, 그라탕, 레시피]

## 4. 단어 빈도수 계산

한국	1639
경제	1533
코로나	231
아이언맨	28
...	...
협찬	1

단어 중 2번 이상 등장하지 않는  
단어 약 74% 삭제  
약 6000개 단어 사용



# 영상 제목 전처리

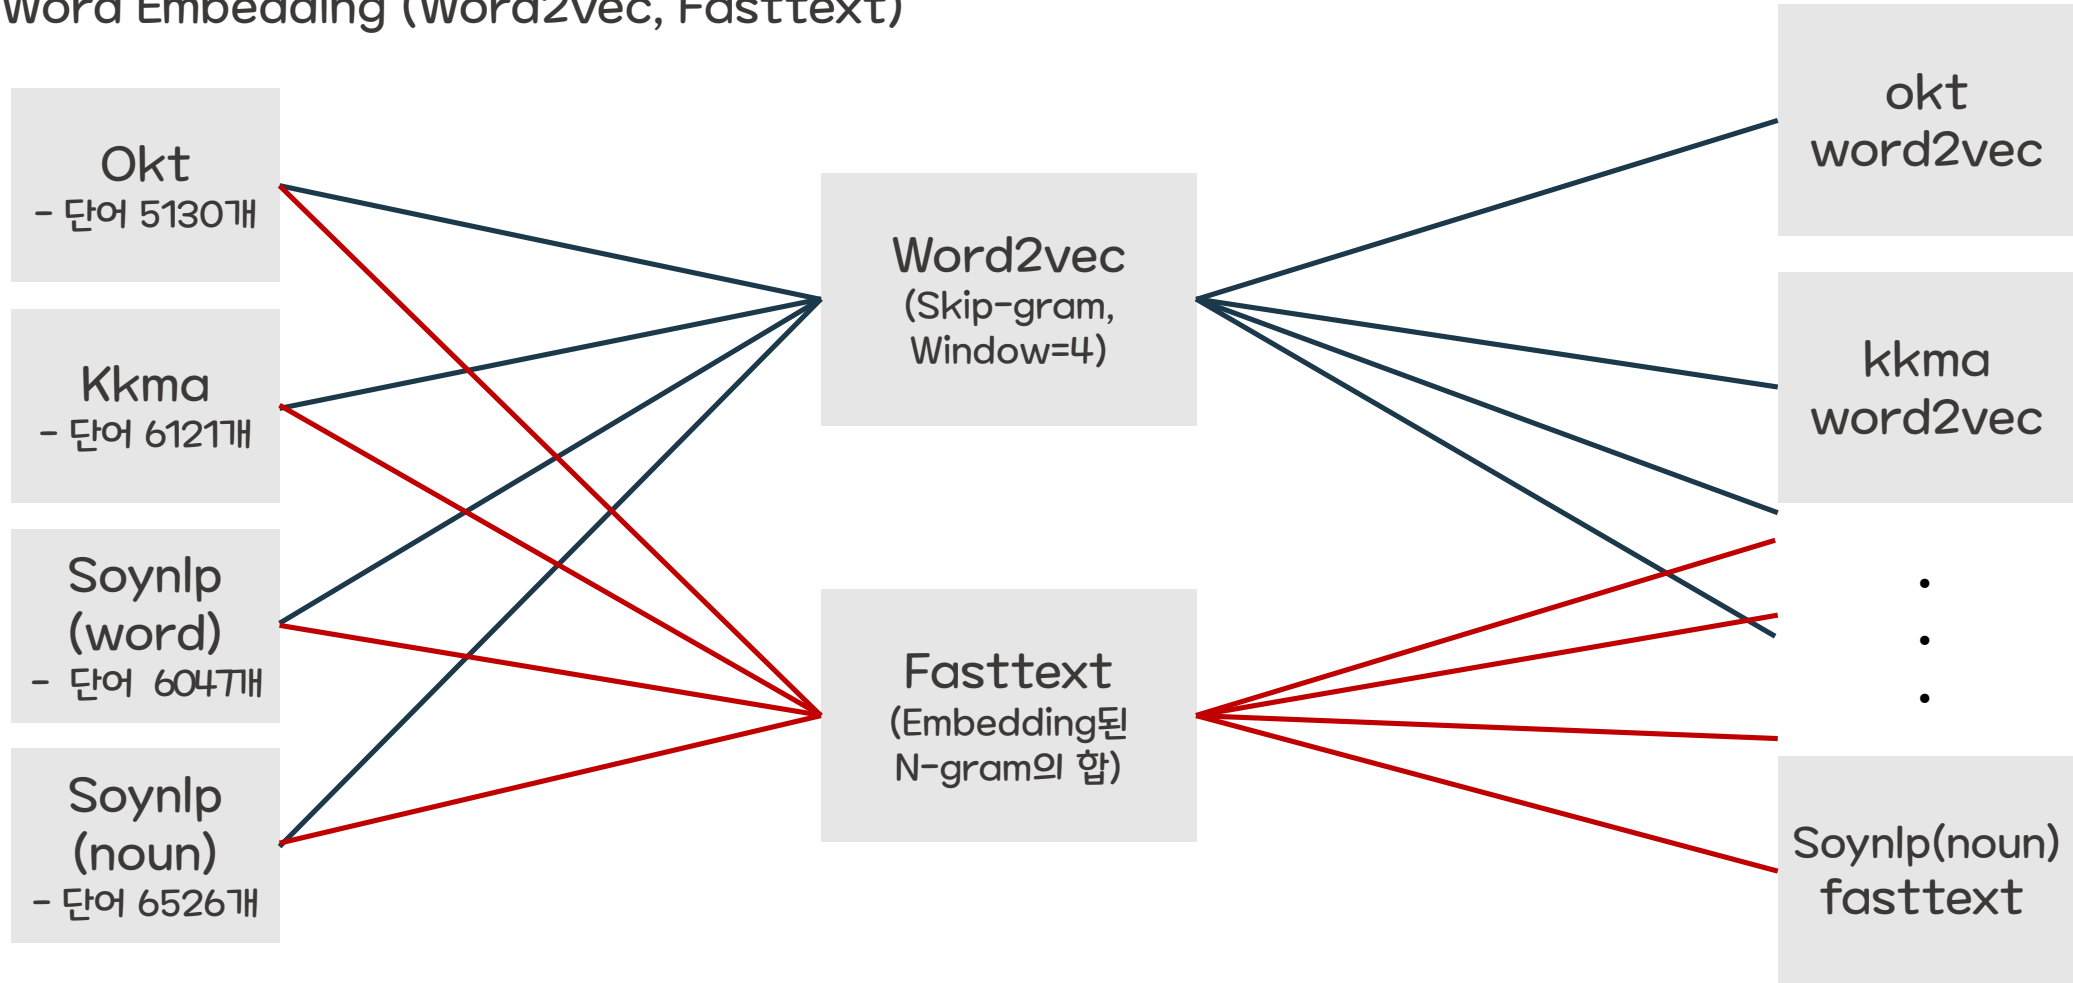
예시 ) 원본 영상 제목과 okt로 명사 토큰화한 제목 비교

영상 제목	Okt로 명사 토큰화한 제목
자기 이름 부르면 돌아보는 고백 형제 (ft.오늘 생일🥳)	자기 이름 고백 형제 오늘 생일
전 프로 선수의 위플볼 마구! 폭풍삼진쇼	프로 선수 위 볼 마구 폭풍 삼진 쇼
좋은에너지를상승시키는법!!!!!!!!!!!!!!	에너지 를 상승 법
하늘에서날라온 귀한선물 귀하신손님3	하늘 귀 선물 손님
사신이 되어 사람들을 마구 죽이는 게임	마구 죽 게임
2018 돈 되는 상가 투자법 제대로 배우기   부동산읽어주는남자	돈 상가 투자 법 제대로 부동산 남자
🔥 우리집은 김장을 안했지만 생각나는 보쌈과 어울리는 식단 오늘의 식단 🔥 [만개의...	김장 보쌈 과 식단 오늘 식단 만 개 레시피
김재원 VS 눈쟁이 배틀그라운드 3만원빵 알까기 대결!	눈 배틀 라운드 만원 빵 대결
양파고추장장아찌₩n/양파장아찌관리법₩n&양파엑기스로장아찌활용방법/	양파 고추장 장아찌 양파 장아찌 관리 법 양파 로 장아찌 활용 방법
다시 보는 2차전지 관련주 '코스모신소재'/이희권의 기업탐방 런투유/한국경제TV	관련 이희 권 기업 탐방 런투유 한국 경제



# 영상 제목 전처리

## 5) Word Embedding (Word2vec, Fasttext)



\* 총 **8가지**의 word Embedding  
1차 성능 평가를 통해 최종 분류 모델에 사용할 형태소 분석기를 정할 것




# ▶ 썸네일 전처리

1) 사이즈 변환 및 keras preprocessing하여 컬러 채널 정규화

[https://i.ytimg.com/vi/NhGSdRgqaZ0/hqdefault.jpg?sqp=-ViZkfAF7o8KeHm9HulPg ...](https://i.ytimg.com/vi/NhGSdRgqaZ0/hqdefault.jpg?sqp=-ViZkfAF7o8KeHm9HulPg...)



(360, 480, 3)



(64, 64, 3)



## 03 1차 모델 생성/예측/평가

- 모델 예측 비교 및 평가




# 모델 예측 비교 및 평가

## 1) 영상 제목만 이용한 분류 모델

		Accuracy	
형태소분석기	단어 임베딩	Logistic Regression	SVC
Soynlp(word)	Word2vec	0.738043	0.774467
	Fasttext	0.766740	0.791391
Soynlp(noun)	Word2vec	0.741316	0.781596
	Fasttext	0.78899	0.810791
Kkma	Word2vec	0.807678	0.838317
	Fasttext	0.840901	0.860465
okt	Word2vec	0.825279	0.847584
	Fasttext	0.843494	0.858364

- Okt\_fasttext의 LR 정확도 그래프



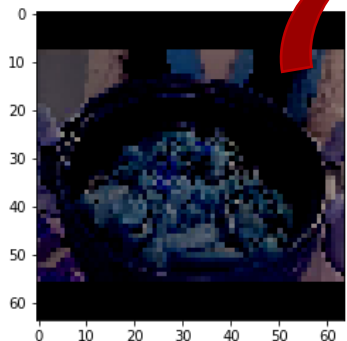
Kkma\_Fasttext 의 SVC 정확도가 가장 높았지만, **kkma의 속도가 매우 느림**

따라서 다음으로 높은 정확도를 보이는 **Okt의 Word2vec, fasttext를 최종 모델 특성추출값으로 사용**



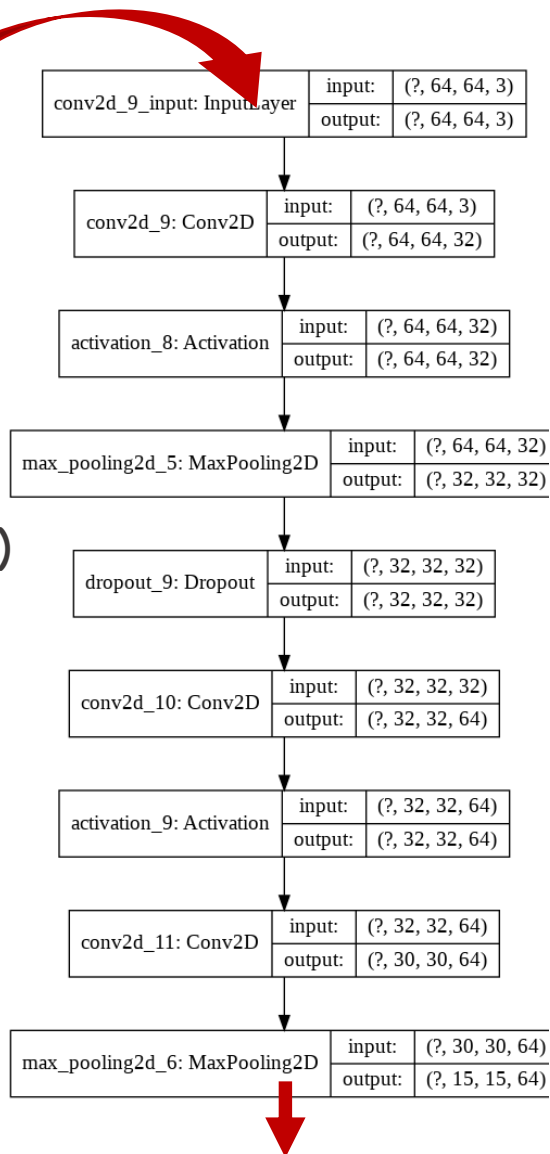


# 모델 예측 비교 및 평가

## 2) 썸네일 이미지만 이용한 분류 모델 – CNN Weight 학습



SHAPE : (64, 64, 3)



- Accuracy = 약 0.81
- Rmsprop loss = 1.4476018495060838


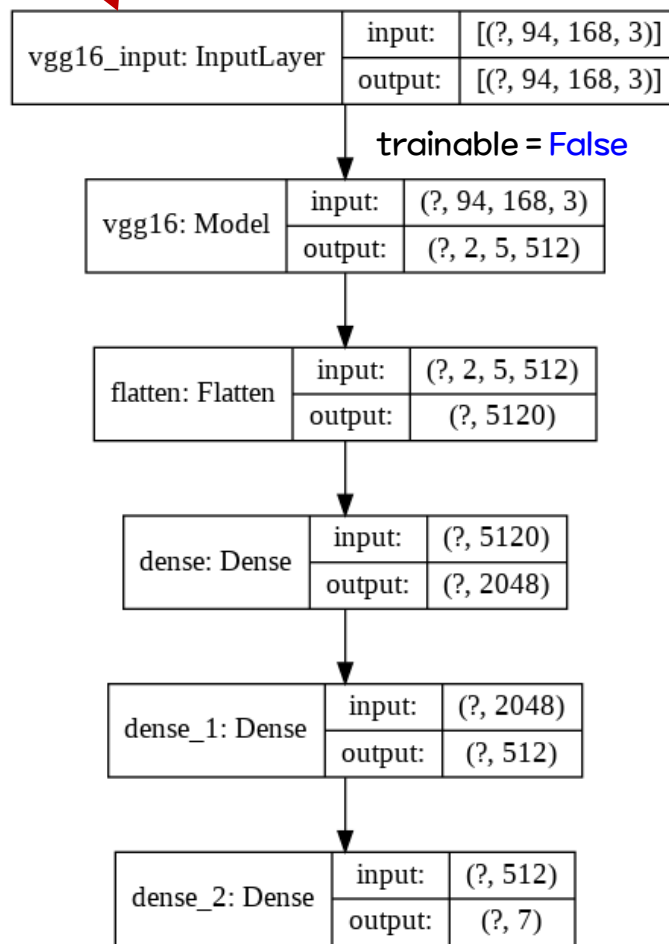


# 모델 예측 비교 및 평가

## 2) 썸네일 이미지만 이용한 분류 모델 – 전이학습 (VGG16)



SHAPE : (94, 168, 3)



- Accuracy = 약 0.82
- rmsprop loss= 1.4476018495060838



## 04 특성 추출

- 영상 제목에서의 특성추출
- 썸네일 이미지에서의 특성추출





# 영상 제목에서의 특성 추출

영상 제목의 Word Embedding 2가지

(1) Okt – Word2vec

	V1	V2	V3	...	V98	V99	V100
sentence1	0.196034	0.245908	0.576134	...	0.176262	-0.258607	0.123638
sentence2	0.198821	0.271698	0.687552	...	0.23243	-0.25477	0.10881
sentence3	0.551256	0.671386	1.551306	...	0.440023	-0.734783	0.317919
sentence4	0.440158	0.614208	1.510556	...	0.598439	-0.470475	0.210407
sentence5	0.359027	0.411707	0.95849	...	0.303726	-0.48153	0.13332
...	...	...	...	...	...	...	...
sentence13621	0.183895	0.809685	0.889106	...	0.386137	-0.576647	-0.307054
sentence13622	0.581141	0.771815	1.442716	...	0.387131	-0.80465	0.111101
sentence13623	0.233537	0.29243	0.859342	...	0.406955	-0.067676	0.00364
sentence13624	0.323732	0.348243	0.788682	...	0.258428	-0.312916	0.070189
sentence13625	0.579369	0.743183	1.59592	...	0.423551	-0.554961	0.153877

SHAPE : (13625 \* 100)

(2) Okt – Fasttext

	V1	V2	V3	...	V98	V99	V100
sentence1	0.523567	-0.391566	0.427402	...	0.636864	0.397615	0.143179
sentence2	0.638376	-0.498384	0.502311	...	0.725406	0.380785	0.168168
sentence3	1.338037	-1.039847	1.181032	...	1.635623	0.942006	0.454793
sentence4	1.318557	-1.087187	1.101964	...	1.54564	0.666304	0.446539
sentence5	0.862312	-0.558923	0.649134	...	1.019527	0.61191	0.245011
...	...	...	...	...	...	...	...
sentence13621	0.942522	-0.647396	0.600209	...	1.316312	0.435052	0.414349
sentence13622	1.335089	-0.878168	1.035238	...	1.646191	1.131196	0.376648
sentence13623	0.557477	-0.804592	0.591	...	0.817633	0.097795	0.260607
sentence13624	0.715465	-0.544113	0.499824	...	0.703478	0.339621	0.180255
sentence13625	1.255596	-1.159646	1.080357	...	1.659805	0.809986	0.246462

SHAPE : (13625 \* 100)


문장의 개수 : 13625개 / 차원 수 : 100



# 썸네일 이미지에서의 특성 추출

## CNN 모델의 Feature Extraction

- Inputs = model, outputs = **model.get\_layer('flatten\_1')** 으로 갖는 flatten\_layer\_model 생성 추출




	0	1	2	3	4	5	6	7	8	7197	7198	7199
0	-0.001158	0.002141	0.008723	-0.000788	0.004164	-0.001598	0.000216	-7.286071e-04	0.001323	-0.008280	-0.001530	0.001487
1	-0.000269	0.002502	0.008250	-0.000779	0.004414	-0.001616	0.000586	-6.588997e-07	0.000928	-0.006611	-0.001796	0.005069
2	-0.001472	0.002528	0.008565	-0.001030	0.004195	-0.001770	0.000601	-1.106166e-03	0.001294	-0.007296	-0.001593	0.003418
3	-0.001088	0.002308	0.008607	-0.000768	0.004255	-0.001672	0.000101	-3.708224e-04	0.000939	-0.006626	-0.001743	0.004797
4	-0.001340	0.002211	0.008743	-0.000668	0.004226	-0.001731	-0.000070	-6.905477e-04	0.001144	-0.006554	-0.001750	0.004813
5	-0.000788	0.002449	0.008436	-0.000797	0.004335	-0.001650	0.000430	-6.423514e-04	0.001037	-0.006573	-0.001754	0.004970
6	-0.000615	0.002377	0.008449	-0.000764	0.004301	-0.001658	0.000263	-2.974104e-04	0.000922	-0.006595	-0.001844	0.005117
7	-0.000781	0.002346	0.008618	-0.000858	0.004197	-0.001719	0.000484	-6.813117e-04	0.001280	-0.007401	-0.001491	0.002569

(13685, 7200)



## VGG16 모델의 Feature Extraction



0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	6.01975594e+01	3.80854106e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	2.50367756e+01	0.00000000e+00
0.00000000e+00	0.00000000e+00	1.73329315e+01	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	1.87533989e+01	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00
0.00000000e+00	0.00000000e+00	0.00000000e+00	0.00000000e+00

(13685, 5120)



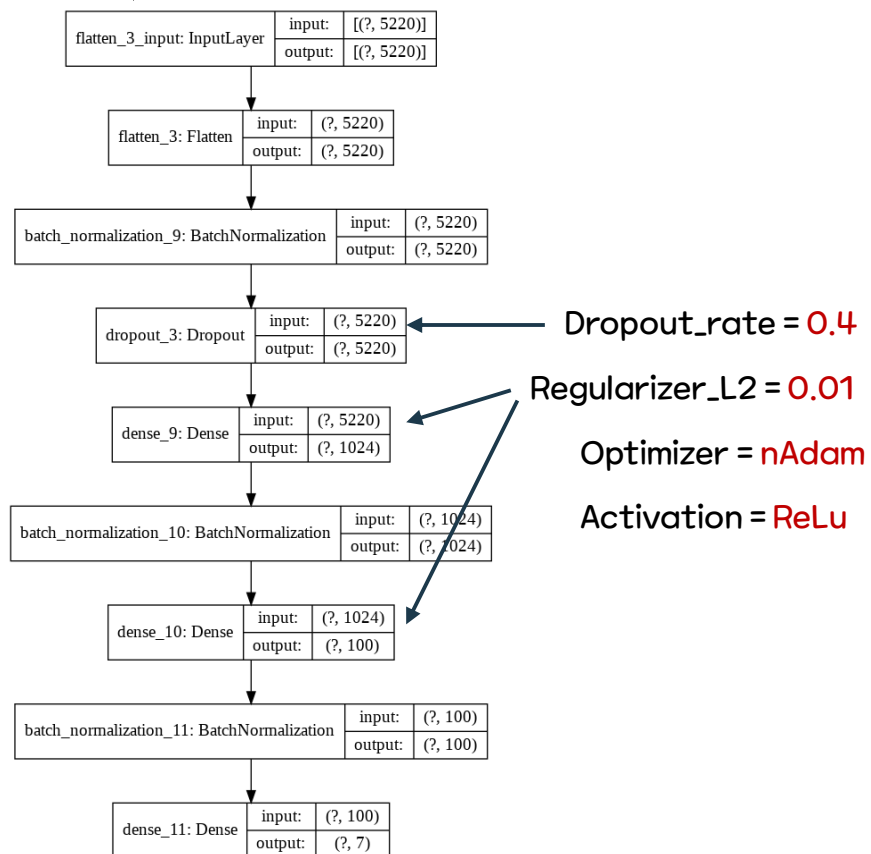
## 05 전체 모델 비교

- VGG16 + Word2vec
- VGG16 + Fasttext
- CNN + Word2vec
- CNN + Fasttext



## “부자가 되기위해 지켜야 할 3가지 원칙 1부 | 부동산업어주는남자”



## Word Embedding







# 전체 모델 비교



## Model 1. VGG + word2vec





## Model 2. VGG + fasttext



## Model 3. CNN + word2vec



## Model 4. CNN + fasttext







# 전체 모델 비교

## Test

```
[ ] score1 = model1.evaluate(x_case1_test, y_case1_test)
    score2 = model2.evaluate(x_case2_test, y_case2_test)
    score3 = model3.evaluate(x_case3_test, y_case3_test)
    score4 = model4.evaluate(x_case4_test, y_case4_test)

85/85 [=====] - 0s 4ms/step - loss: 0.8520 - accuracy: 0.8752
85/85 [=====] - 0s 4ms/step - loss: 0.7800 - accuracy: 0.8874
85/85 [=====] - 0s 4ms/step - loss: 0.7708 - accuracy: 0.8358
85/85 [=====] - 0s 4ms/step - loss: 0.8205 - accuracy: 0.8370
```



	Loss	Accuracy
VGG+w2v	0.852	87.52%
VGG+Fxt	0.78	88.74%
CNN+Fxt	0.7706	83.56%
CNN+w2v	0.8205	83.70%



## 06 결과 해석



## 결과해석





## 결과해석

```
["cooking", "economy", "game", "movie", "pets", "politics", "sports"]
```



Predicted

0

1

2

3

4

5

6

True

0

346

1

12

7

2

1

3

1

1

333

5

0

1

11

3

2

4

3

317

9

3

12

26

3

1

0

18

60

6

6

10

4

16

0

12

8

358

0

8

5

5

3

11

5

3

683

10

6

7

1

37

8

7

20

314



THANK YOU